

Referências

Realidade de Empresas Produtoras de Soluções de IA

Organização por Tema

1. Fundamentos e economia da IA nos negócios;
2. Processo e metodologia de Machine Learning;
3. Engenharia de sistemas de ML e MLOps;
4. Produto e experiência de IA;
5. Estratégia, adoção e ROI nas empresas;
6. Governança, ética e risco.

Este documento reúne uma seleção de referências de apoio ao estudo sobre a realidade das empresas produtoras de soluções de Inteligência Artificial, organizadas por tema. A seleção combina livros de referência, artigos seminais, frameworks oficiais e relatórios do setor. Cada item traz uma anotação curta indicando o que a fonte oferece e por que é útil.

1. Fundamentos e economia da IA nos negócios

AGRAWAL, Ajay; GANS, Joshua; GOLDFARB, Avi. **“Prediction Machines: The Simple Economics of Artificial Intelligence”**. Harvard Business Review Press, 2018 (edição revista e ampliada, 2022).

Enquadra a IA como uma queda no custo da previsão e mostra como isso muda decisões, fluxos de trabalho e modelos de negócio. Boa porta de entrada para pensar onde a IA gera valor econômico.

IANSENTI, Marco; LAKHANI, Karim R. **“Competing in the Age of AI: Strategy and Leadership When Algorithms and Networks Run the World”**. Harvard Business Review Press, 2020.

Descreve o modelo operacional das empresas centradas em IA, em que dados e algoritmos, e não apenas pessoas, ficam no núcleo da entrega de valor, com efeitos de escala e escopo.

DAUGHERTY, Paul R.; WILSON, H. James. **“Human + Machine: Reimagining Work in the Age of AI”**. Harvard Business Review Press, 2018.

Foca na colaboração entre pessoas e máquinas e no redesenho de processos, apresentando os novos papéis que surgem quando a IA entra no fluxo de trabalho.

FONTANA, Ash. **“The AI-First Company: How to Compete and Win with Artificial Intelligence”**. Portfolio / Penguin, 2021.

Guia prático de como construir e escalar uma empresa orientada a dados e IA, incluindo ciclos de dados, vantagens competitivas defensáveis e etapas de maturidade.

2. Processo e metodologia de Machine Learning

STUDER, S.; BUI, T. B.; DRESCHER, C.; HANUSCHKIN, A.; WINKLER, L.; PETERS, S.; MÜLLER, K.-R. **“Towards CRISP-ML(Q): A Machine Learning Process Model with Quality Assurance Methodology”**. Machine Learning and Knowledge Extraction, v. 3, n. 2, p. 392–413, 2021. DOI: <https://doi.org/10.3390/make3020020>.

Modelo de processo em seis fases, da definição de escopo à manutenção em produção, estendendo o CRISP-DM com garantia de qualidade e gestão de riscos específica de ML.

ML-OPS.ORG. “**CRISP-ML(Q): The ML Lifecycle Process**”. Disponível em: <https://ml-ops.org/content/crisp-ml>.

Versão prática e resumida do CRISP-ML(Q) em formato web, boa para consulta rápida das fases e das tarefas de qualidade em cada etapa do ciclo de vida.

SCULLEY, D.; HOLT, G.; GOLOVIN, D.; DAVYDOV, E.; PHILLIPS, T.; EBNER, D.; CHAUDHARY, V.; YOUNG, M.; CRESPO, J.-F.; DENNISON, D. “**Hidden Technical Debt in Machine Learning Systems**”. Advances in Neural Information Processing Systems (NeurIPS), v. 28, p. 2503–2511, 2015.

Artigo seminal que mostra por que sistemas de ML acumulam custo de manutenção oculto, com anti-padrões como emaranhamento, dependências de dados e laços de realimentação escondidos.

SATO, Danilo; WIDER, Arif; WINDHEUSER, Christoph. “**Continuous Delivery for Machine Learning**”. martinowler.com, 2019. Disponível em: <https://martinfowler.com/articles/cd4ml.html>.

Explica como aplicar entrega contínua a ML, versionando dados, modelos e código e automatizando o pipeline do treino ao deploy, com um exemplo de ponta a ponta.

3. Engenharia de sistemas de ML e MLOps

HUYEN, Chip. “**Designing Machine Learning Systems: An Iterative Process for Production-Ready Applications**”. O’Reilly Media, 2022.

Referência sobre projetar sistemas de ML de ponta a ponta para produção, cobrindo dados, features, treino, avaliação, deploy e monitoramento, com foco em decisões de engenharia.

HUYEN, Chip. “**AI Engineering: Building Applications with Foundation Models**”. O’Reilly Media, 2025.

Complementa o livro anterior com foco em construir aplicações sobre foundation models e LLMs, cobrindo avaliação, prompt engineering, RAG, fine-tuning, agentes e otimização de inferência.

LAKSHMANAN, Valliappa; ROBINSON, Sara; MUNN, Michael. “**Machine Learning Design Patterns**”. O’Reilly Media, 2020.

Catálogo de padrões recorrentes para preparação de dados, representação de features, treino, serving e reprodutibilidade, útil para resolver problemas comuns sem reinventar a roda.

ZINKEVICH, Martin. “**Rules of Machine Learning: Best Practices for ML Engineering**”. Google. Disponível em: <https://developers.google.com/machine-learning/guides/rules-of-ml>.

Conjunto de regras práticas de engenharia de ML escritas a partir da experiência do Google em operar modelos em escala, com forte ênfase em simplicidade e em dados antes de sofisticação.

GOOGLE CLOUD. “**MLOps: Continuous Delivery and Automation Pipelines in Machine Learning**”. Disponível em: <https://cloud.google.com/architecture/mlops-continuous-delivery-and-automation-pipelines-in-machine-learning>.

Documento de arquitetura que descreve níveis de maturidade de MLOps e como montar CI/CD, treino contínuo e monitoramento de modelos em produção.

MOHANDAS, Goku. “**Made With ML**”. Disponível em: <https://madewithml.com>.

Curso aberto e prático que conecta boas práticas de engenharia de software com MLOps, do design e teste ao deploy e à operação de aplicações de ML.

4. Produto e experiência de IA

GOOGLE PAIR. “**People + AI Guidebook**”. Google, 2019. Disponível em: <https://pair.withgoogle.com/guidebook>.

Guia com boas práticas para desenhar produtos de IA centrados no usuário, cobrindo definição de necessidades, confiança, explicabilidade, tratamento de erros e feedback.

AMERSHI, Saleema *et al.* “**Guidelines for Human-AI Interaction**”. Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems. DOI: <https://doi.org/10.1145/3290605.3300233>. Ferramentas em: <https://www.microsoft.com/en-us/haxtoolkit/>.

Conjunto de 18 diretrizes validadas para a interação entre pessoas e sistemas de IA, com padrões de design e exemplos reunidos no HAX Toolkit da Microsoft.

5. Estratégia, adoção e ROI nas empresas

PEREIRA, Elisa; GRAYLIN, Alvin Wang; BRYNJOLFSSON, Erik. “**The Enterprise AI Playbook: Lessons from 51 Successful Deployments**”. Stanford Digital Economy Lab, Stanford University, 2026. Disponível em: <https://digitaleconomy.stanford.edu>.

Reúne lições de 51 implantações reais de IA em empresas, mostrando que o sucesso depende menos da tecnologia e mais de redesenho de processos, patrocínio executivo e governança.

MCKINSEY & COMPANY (QuantumBlack). “**The State of AI**”. 2025. Disponível em: <https://www.mckinsey.com/capabilities/quantumblack/our-insights/the-state-of-ai>.

Pesquisa anual sobre adoção de IA nas empresas, mostrando onde o valor aparece, quanto poucas organizações capturam retorno significativo e o que as diferencia.

STANFORD HAI. “**The AI Index Report 2025**”. Stanford Institute for Human-Centered AI, 2025.

Disponível em: <https://hai.stanford.edu/ai-index/2025-ai-index-report>.

Relatório anual que agrega dados sobre pesquisa, economia, adoção, política e riscos de IA. Fonte confiável de números atualizados para fundamentar argumentos.

VANIUKOV, Slava. “**How to Measure ROI from AI Projects: KPIs, Frameworks & Templates**”.

Softermii, 2026. Disponível em: <https://softermii.com/blog/artificial-intelligence/how-to-measure-roi-from-ai-projects-kpis-frameworks-and-templates>.

Explica a fórmula de ROI adaptada a projetos de IA, as categorias de valor (custo, receita e risco), KPIs financeiros e operacionais e traz templates prontos de cálculo.

WORKLYTICS. “**Proving ROI on AI Adoption: Metrics and Dashboards**”. Worklytics, 2025.

Disponível em: <https://www.worklytics.co/resources/proving-roi-ai-adoption-metrics-dashboards-2025>.

Foca em métricas e dashboards para provar o retorno da adoção de IA, com ênfase em medir uso, produtividade e impacto ao longo do tempo.

AGILITY AT SCALE. “**AI Business Impact Metrics**”. Disponível em: <https://agility-at-scale.com/ai/strategy/ai-business-impact-metrics/>.

Apresenta um conjunto de métricas de impacto de negócio para estratégia de IA, ajudando a ligar iniciativas técnicas a resultados mensuráveis para a organização.

6. Governança, ética e risco

NIST. “**Artificial Intelligence Risk Management Framework (AI RMF 1.0)**”. National Institute of Standards and Technology, 2023. Disponível em: <https://www.nist.gov/itl/ai-risk-management-framework>.

Framework voluntário organizado em quatro funções, Governar, Mapear, Medir e Gerenciar, para tratar riscos de sistemas de IA ao longo de todo o ciclo de vida.

ISO/IEC. “**ISO/IEC 42001:2023: Sistema de Gestão de Inteligência Artificial**”. International Organization for Standardization, 2023. Disponível em: <https://www.iso.org/standard/42001>.

Primeira norma internacional de sistema de gestão de IA. Define requisitos para desenvolver, fornecer e usar IA de forma responsável, auditável e passível de certificação.

PARLAMENTO EUROPEU; CONSELHO DA UNIÃO EUROPEIA. “**Regulamento (UE) 2024/1689 (AI Act)**”. 2024. Disponível em: <https://artificialintelligenceact.eu>.

Primeiro marco regulatório abrangente de IA, com abordagem baseada em risco que classifica os sistemas e impõe obrigações proporcionais ao nível de risco de cada um.

OCDE. **“OECD AI Principles”**. Organização para a Cooperação e Desenvolvimento Econômico, 2019 (atualizados em 2024). Disponível em: <https://oecd.ai/en/ai-principles>.

Princípios intergovernamentais para uma IA confiável, que servem de base para diversas políticas e regulações de IA adotadas no mundo.