



GUIA DE REFERÊNCIA

Anatomia da Proposta Técnico-Comercial

Soluções de Inteligência Artificial e Machine Learning

O que é este documento

Referência que detalha, parte por parte, o que uma proposta técnico-comercial de IA/ML deve conter, da capa às referências. Não é uma proposta pronta, e sim um guia de especificações, boas práticas e erros a evitar, com as fontes usadas em cada parte.

Conteúdo

01. Capa	3
02. Sumário Executivo	4
03. Entendimento do Problema e Contexto	4
04. Objetivos e Critérios de Sucesso	5
05. Solução Proposta e Abordagem Técnica	6
06. Requisitos e Governança de Dados	6
07. Escopo	7
08. Metodologia e Fases do Projeto	8
09. Entregáveis e Critérios de Aceite	9
10. Cronograma e Marcos	9
11. Equipe e Estimativa de Esforço	10
12. Riscos e Dependências	11
13. Métricas, KPIs e ROI	11
14. Operação: Monitoramento e Manutenção	12
15. Governança, Ética, Segurança e Conformidade	13
16. Investimento e Condições Comerciais	13
17. Credibilidade e Prova	14
18. Próximos Passos, Validade e Anexos	14
Referências	16

Como usar este documento

Cada parte a seguir corresponde a uma seção de uma proposta técnico-comercial de IA/ML, apresentada na ordem em que normalmente aparece no documento final. Para cada parte, você encontra o objetivo, o que incluir com as especificações, uma caixa de boas práticas específicas de IA/ML, uma caixa de erros comuns a evitar e as fontes mais usadas naquela parte. Ao final, a seção de Referências reúne as fontes completas, agrupadas pela parte em que cada uma foi mais utilizada. Use este material como uma lista de verificação ao montar propostas, adaptando a profundidade de cada seção ao tamanho do projeto e ao perfil de quem vai ler.

01 Capa

Objetivo

Identificar a proposta e transmitir profissionalismo em poucos segundos, deixando claro para quem é o documento e sobre o que ele trata.

O que incluir

- Título do projeto orientado ao resultado do cliente, não ao seu produto;
- Nome do cliente e do fornecedor;
- Data e número de versão da proposta;
- Identificação de confidencialidade, quando aplicável;
- Contato do responsável pela proposta;
- Identidade visual limpa e consistente com o restante do documento.

Boas práticas para IA/ML

- Personalize o título e cite o nome do cliente; capa genérica sinaliza proposta genérica;
- Mantenha data e versão visíveis para controle de revisões;
- Deixe o visual sóbrio e legível, sem excesso de elementos.

Erros comuns a evitar

- Capa sem o nome do cliente ou sem data e versão;
- Excesso de jargão técnico logo na abertura.

Fontes mais usadas: [ProposalKit], [AutoRFP]

02 Sumário Executivo

Objetivo

Resumir, para quem decide e muitas vezes não é técnico, o problema, a solução e o valor, de forma autossuficiente. É a seção mais lida, então deve funcionar sozinha.

O que incluir

- O problema do cliente em uma ou duas frases;
- A solução proposta em alto nível;
- O resultado esperado e a métrica principal de sucesso;
- Investimento e prazo em faixa, para dar ordem de grandeza;
- Um chamado à ação claro para o próximo passo.

Boas práticas para IA/ML

- Escreva por último e posicione primeiro; foque em resultado de negócio;
- Garanta que o texto seja compreensível sem ler o resto da proposta;
- Traduza a técnica em benefício, sem jargão.

Erros comuns a evitar

- Começar pela tecnologia em vez do problema do cliente;
- Escrever para o leitor técnico quando quem decide é o negócio;
- Prometer acurácia garantida.

Fontes mais usadas: [Aviy], [AutoRFP], [Cobrief]

03 Entendimento do Problema e Contexto

Objetivo

Mostrar que você entende o negócio do cliente melhor do que qualquer concorrente, conectando o problema à estratégia dele.

O que incluir

- Contexto do cliente e as dores atuais;
- Impacto do problema no negócio, com dimensionamento quando possível;
- Stakeholders e decisores envolvidos;
- Restrições conhecidas (orçamento, prazo, sistemas, dados);
- Por que agora, ou seja, o que torna o momento oportuno.

Boas práticas para IA/ML

- Lidere pela dor do cliente antes de falar de você;
- Use dados do setor para dimensionar a oportunidade;
- Conecte o problema aos objetivos estratégicos do cliente.

Erros comuns a evitar

- Falar da sua empresa antes de falar do cliente;
- Apresentar suposições não validadas como se fossem fatos.

Fontes mais usadas: [Aviy], [Prediction Machines], [McKinsey], [AI Index], [Enterprise AI Playbook]

04 Objetivos e Critérios de Sucesso

Objetivo

Definir, de forma mensurável, o que é sucesso, tanto no negócio quanto no técnico. É a base que sustenta escopo, preço e aceite.

O que incluir

- Objetivo de negócio, específico e datado (por exemplo, reduzir o churn em um percentual em um horizonte);
- Critério de sucesso de negócio, com a métrica que comprova o resultado;
- Critério de sucesso técnico do ML (por exemplo, métrica alvo e limiar aceitável);
- Horizonte de medição e forma de verificação;
- Baseline atual, medido antes do projeto.

Boas práticas para IA/ML

- Alinhe o critério técnico ao objetivo de negócio, não ao contrário;
- Estabeleça o baseline antes de começar, senão não há como provar melhoria;
- Separe claramente o que é hipótese do que é compromisso contratual.

Erros comuns a evitar

- Prometer uma acurácia específica antes de ver os dados;
- Medir apenas a métrica técnica, desconectada do negócio;
- Iniciar sem baseline.

Fontes mais usadas: [CRISP-ML(Q)], [DataSciencePM], [nexocode]

05 Solução Proposta e Abordagem Técnica

Objetivo

Descrever o que o cliente vai receber e como você vai construir, traduzindo cada escolha técnica em resultado de negócio.

O que incluir

- Visão da solução, ou seja, o que o cliente terá em mãos ao final;
- Arquitetura em alto nível e integração com os sistemas do cliente;
- Abordagem de modelagem, com as alternativas consideradas e a escolhida;
- Decisão entre construir, contratar ou usar foundation models, quando couber;
- Experiência de entrega e de uso (dashboard, API, copiloto), com foco em confiança e explicabilidade.

Boas práticas para IA/ML

- Traduza cada decisão técnica em benefício para o cliente;
- Comece por um baseline simples antes de propor algo sofisticado;
- Leve o jargão pesado para um anexo técnico.

Erros comuns a evitar

- Overengineering, propor o modelo mais complexo por status;
- Arquitetura sem ligação clara com o problema;
- Prometer sofisticação sem provar valor primeiro.

Fontes mais usadas: [Aviy], [ProposalKit], [Huyen 2022], [Huyen 2025], [PAIR]

06 Requisitos e Governança de Dados

Objetivo

Deixar explícito de quais dados o projeto depende. Em ML, os dados são o maior risco e o maior consumidor de esforço, então essa parte protege as duas partes.

O que incluir

- Fontes de dados necessárias e onde vivem;
- Volume, histórico e frequência de atualização;
- Qualidade esperada e responsabilidade por ela;
- Acesso, credenciais e ambiente de trabalho;

- Privacidade e base legal (LGPD), propriedade e retenção dos dados.

Boas práticas para IA/ML

- Trate o acesso a dados como premissa e dependência explícita;
- Reserve uma fatia grande do esforço para preparação de dados, algo entre 40 e 60%;
- Combine, por escrito, de quem é a responsabilidade pela qualidade dos dados.

Erros comuns a evitar

- Assumir que os dados já estão prontos e limpos;
- Ignorar a base legal do uso dos dados;
- Subestimar o trabalho de limpeza e integração.

Fontes mais usadas: [CRISP-ML(Q)], [Sculley 2015], [Huyen 2022], [NMS SOW]

07 Escopo

Objetivo

Delimitar com precisão o que será e o que não será feito, para evitar o escopo inchado que corrói prazo e margem.

O que incluir

- Itens dentro do escopo, organizados por frente de trabalho;
- Itens explicitamente fora do escopo;
- Premissas que sustentam o escopo;
- Dependências e insumos que o cliente precisa fornecer;
- Processo de mudança de escopo (change request).

Boas práticas para IA/ML

- Liste o fora do escopo com o mesmo cuidado do dentro do escopo;
- Use linguagem de ação e quebre tarefas complexas;
- Conecte o escopo diretamente ao preço.

Erros comuns a evitar

- Escopo vago que abre espaço para interpretações;
- Deixar as exclusões implícitas;
- Não ter um processo definido para mudanças.

08 Metodologia e Fases do Projeto

Objetivo

Mostrar um processo confiável e adequado à incerteza do ML, dando previsibilidade sem esconder a natureza iterativa do trabalho.

O que incluir

- O nome do framework citado uma vez (por exemplo, CRISP-ML(Q));
- As seis fases traduzidas em marcos e entregáveis, não em tarefas acadêmicas;
- Engajamento em fases, com uma etapa curta de descoberta e viabilidade antes de fechar o restante;
- Pontos de decisão go/no-go entre as fases.

O quadro a seguir mostra como as fases do CRISP-ML(Q) se traduzem em seções da proposta, que é a forma recomendada de citar a metodologia sem despejar jargão.

Fase do CRISP-ML(Q)	Onde aparece na proposta
Entendimento de negócio e dados	Sumário executivo, entendimento do problema, objetivos e critérios, requisitos de dados.
Preparação de dados	Escopo, cronograma (fatia grande do esforço), premissas de acesso a dados.
Modelagem	Abordagem técnica e entregáveis (baseline e modelo).
Avaliação	Critérios de aceite, métricas e KPIs.
Deploy	Entregáveis, cronograma e integração.
Monitoramento e manutenção	Operação (MLOps), garantias e condições comerciais recorrentes.

Boas práticas para IA/ML

- Combine uma implementação leve do CRISP com gestão ágil;
- Coloque uma fase curta de descoberta e viabilidade antes de fechar escopo e preço;
- Deixe explícita a iteração entre modelagem e avaliação.

Erros comuns a evitar

- Recitar as tarefas acadêmicas de cada fase no corpo da proposta;
- Um contrato único de escopo fechado que ignora a incerteza do ML;
- Jargão de metodologia no sumário executivo.

09 Entregáveis e Critérios de Aceite

Objetivo

Listar as saídas tangíveis do projeto e definir como cada uma será considerada aceita, eliminando ambiguidade no fechamento.

O que incluir

- Cada entregável com seu formato (modelo, código, documentação, relatório de avaliação, dashboard);
- Critério de aceite mensurável para cada entregável;
- Quem aprova e em quanto tempo;
- Distinção clara entre protótipo e versão de produção.

Boas práticas para IA/ML

- Todo entregável precisa de um critério de aceite verificável;
- Inclua documentação e relatório de avaliação como entregáveis, não só o modelo;
- Defina o que significa concluído para cada item.

Erros comuns a evitar

- Entregável sem critério de aceite;
- Usar expressões como modelo funcionando sem definir o que é funcionar.

Fontes mais usadas: [NMS SOW], [AutoRFP], [Cobrief], [nexocode]

10 Cronograma e Marcos

Objetivo

Mostrar o prazo por fase e os marcos que comprovam progresso, criando um ritmo verificável para o projeto.

O que incluir

- Fases com duração, entradas, saídas e dependências;
- Marcos e pontos de decisão;
- Cadência de acompanhamento (por exemplo, semanal);
- Premissas que sustentam os prazos.

Boas práticas para IA/ML

- Estruture os prazos pelas fases do CRISP-ML(Q);
- Amarre cada marco a um entregável concreto;
- Reserve tempo realista para preparação de dados.

Erros comuns a evitar

- Cronograma sem dependências entre fases;
- Prometer uma data única sem faseamento;
- Subestimar o tempo de dados.

Fontes mais usadas: [AutoRFP], [Cobrief], [CRISP-ML(Q)]

11 Equipe e Estimativa de Esforço

Objetivo

Mostrar quem executa e como o esforço e o preço foram estimados, dando credibilidade aos números.

O que incluir

- Papéis envolvidos (engenharia de dados, engenharia de ML e ciência de dados, MLOps, produto e UX, segurança e jurídico);
- Alocação por fase;
- Técnica de estimativa usada (paramétrica, PERT, pontos de função);
- Margem de risco aplicada.

Boas práticas para IA/ML

- Estime por fase, lembrando que dados costumam representar de 40 a 60% do esforço;
- Use PERT quando houver incerteza alta;
- Considere a produtividade real, menor que oito horas efetivas por dia.

Erros comuns a evitar

- Estimar apenas o treino do modelo;
- Uma equipe sem MLOps nem governança;
- Não aplicar margem de risco.

Fontes mais usadas: [CRISP-ML(Q)], [Infodiagram]

12 Riscos e Dependências

Objetivo

Antecipar o que pode dar errado e transformar isso em premissas, ressalvas e margem, de forma honesta.

O que incluir

- Riscos de dados (insuficiência, qualidade, viés);
- Risco de drift e degradação do modelo ao longo do tempo;
- Dependências do cliente (acesso, aprovações, disponibilidade);
- Riscos legais e éticos;
- Plano de mitigação para cada risco relevante.

Boas práticas para IA/ML

- Derive os riscos das próprias fases do CRISP-ML(Q);
- Use os anti-padrões de dívida técnica de ML como checklist;
- Transforme cada risco em cláusula, premissa ou margem.

Erros comuns a evitar

- Omitir riscos para parecer mais competitivo;
- Prometer resultados sem ressalvas;
- Ignorar a manutenção e a dívida técnica futuras.

Fontes mais usadas: [NMS SOW], [CRISP-ML(Q)], [Sculley 2015], [ProposalKit]

13 Métricas, KPIs e ROI

Objetivo

Ligar a solução a valor mensurável para o negócio, mostrando como o retorno será acompanhado.

O que incluir

- KPIs financeiros (redução de custo, receita, ROI, payback);
- KPIs operacionais (tempo de ciclo, taxa de automação, taxa de erro);
- KPIs de modelo ligados a impacto financeiro, não só à acurácia;
- Horizonte de realização do valor, que em IA costuma ser gradual.

Boas práticas para IA/ML

- Conecte cada métrica de modelo a um impacto de negócio em dinheiro;
- Defina o baseline para tornar o ROI verificável;
- Atribua um dono para cada KPI.

Erros comuns a evitar

- Medir acurácia em vez de impacto;
- Prometer ROI sem baseline;
- KPIs sem responsável definido.

Fontes mais usadas: [Softermii], [Worklytics], [Agility at Scale]

14 Operação: Monitoramento e Manutenção

Objetivo

Tratar a IA como um sistema vivo. Essa parte sustenta tecnicamente o modelo comercial recorrente e evita a degradação silenciosa do modelo.

O que incluir

- Monitoramento de desempenho e de drift;
- Retreino e versionamento de dados e modelos;
- SLAs e modelo de suporte;
- Pipelines de CI/CD e treino contínuo;
- Plano de rollback quando uma atualização falha.

Boas práticas para IA/ML

- Inclua monitoramento e retreino dentro do escopo e do preço;
- Use MLOps para evitar que o modelo degrade sem ninguém perceber;
- Ligue essa operação à condição comercial recorrente.

Erros comuns a evitar

- Tratar IA como algo de entregar e esquecer;
- Entregar sem monitoramento;
- Não versionar dados e modelos.

Fontes mais usadas: [Google Cloud MLOps], [CD4ML], [Sculley 2015], [Huyen 2022]

15 Governança, Ética, Segurança e Conformidade

Objetivo

Mostrar que a solução é responsável, segura e auditável, o que é cada vez mais um critério de compra.

O que incluir

- Gestão de risco de IA, apoiada em um framework como o NIST AI RMF;
- Sistema de gestão de IA, alinhado a uma norma como a ISO/IEC 42001;
- Enquadramento regulatório (LGPD, AI Act) e a classificação de risco do sistema;
- Segurança e privacidade dos dados e do modelo;
- Explicabilidade e supervisão humana onde fizer sentido.

Boas práticas para IA/ML

- Dimensione os controles de forma proporcional ao risco do caso;
- Documente decisões e mantenha trilha de auditoria;
- Ofereça explicabilidade adequada ao usuário final.

Erros comuns a evitar

- Ignorar a base legal e a classificação de risco;
- Tratar segurança como um anexo esquecido;
- Prometer conformidade sem um processo por trás.

Fontes mais usadas: [NIST AI RMF], [ISO 42001], [AI Act], [PAIR]

16 Investimento e Condições Comerciais

Objetivo

Deixar preço e condições cristalinos e ligados a marcos, de forma que o cliente entenda pelo que está pagando e quando.

O que incluir

- Modelo de cobrança (fixo por fase, por resultado, assinatura ou AlaaS);
- Tabela de preços por elemento do projeto;
- Condições de pagamento amarradas a marcos e entregáveis;
- Validade da proposta e regras de reajuste e recorrência.

Boas práticas para IA/ML

- Amarre o faturamento a marcos e entregáveis verificáveis;
- Ofereça a fase de descoberta com preço próprio, separada da execução;
- Deixe a recorrência de monitoramento explícita no preço.

Erros comuns a evitar

- Um preço único e opaco;
- Condições de pagamento confusas;
- Misturar descoberta e execução num único valor fechado.

Fontes mais usadas: [Aviy], [Infodiagram], [NMS SOW]

17 Credibilidade e Prova

Objetivo

Construir a confiança de que você entrega, com evidências concretas e não com afirmações genéricas.

O que incluir

- Cases e resultados nomeados e verificáveis;
- Equipe e experiência relevante;
- Depoimentos e referências de clientes;
- Certificações e parcerias, quando pertinentes.

Boas práticas para IA/ML

- Use prova específica, com número e resultado, não claim genérico;
- Conecte o case ao problema do cliente atual.

Erros comuns a evitar

- Afirmações vagas sem evidência;
- Uma seção só sobre você, desconectada do cliente.

Fontes mais usadas: [AutoRFP], [Aviy], [Infodiagram]

18 Próximos Passos, Validade e Anexos

Objetivo

Facilitar o sim e conectar a proposta ao contrato, reduzindo o atrito para avançar.

O que incluir

- Um próximo passo simples (por exemplo, alinhar objetivos ou liberar uma amostra de dados);
- Validade da proposta;
- Anexos: SOW e contrato (MSA), arquitetura, plano de dados e glossário técnico.

Boas práticas para IA/ML

- Termine com momentum e um passo fácil de dar;
- Ligue os marcos da proposta ao SOW e ao contrato;
- Leve o detalhe técnico pesado para os anexos.

Erros comuns a evitar

- Encerrar sem chamada à ação;
- Deixar a proposta solta do contrato;
- Não informar a validade.

Fontes mais usadas: [Cobrief], [Aviy], [NMS SOW], [AutoRFP]

Referências

As fontes abaixo estão agrupadas pela parte da proposta em que cada uma foi mais utilizada. As chaves entre colchetes são as mesmas citadas em Fontes mais usadas ao longo do documento.

Estrutura e redação da proposta (partes 01, 02, 09, 10, 17, 18)

[Aviy] AVIY. “**AI Consulting Proposal Template**”. Aviy, 2026. Disponível em: <https://aviy.ai/blog/ai-consulting-proposal-template>.

Estrutura de proposta de consultoria em IA orientada a resultado, com faseamento para reduzir risco e ligação entre marcos e faturamento.

[ProposalKit] PROPOSAL KIT. “**How to Write an AI Project Proposal**”. Proposal Kit, 2026. Disponível em: <https://www.proposalkit.com/htm/how-to-write-an-ai-project-proposal.htm>.

Aponta as seções próprias de projetos de IA, como imprevisibilidade, monitoramento contínuo e questões legais e éticas.

[AutoRFP] AUTORFP. “**Technical Proposal: How to Write One That Wins**”. AutoRFP.ai, 2026. Disponível em: <https://autorfp.ai/blog/technical-proposal>.

Estrutura geral de uma proposta técnica, incluindo abordagem técnica, entregáveis, gestão de risco, governança e marcos.

[Cobrief] COBRIEF. “**Machine Learning Prototype Proposal (Template)**”. Cobrief, 2025. Disponível em: <https://www.cobrief.app/resources/business-proposal-templates/machine-learning-prototype-proposal-free-template/>.

Modelo de proposta de protótipo de ML, com foco em derriscar antes de escalar e em explicar tradeoffs em linguagem simples.

[Infodiagram] INFODIAGRAM. “**How to Present an AI Project Proposal**”. Infodiagram, 2024. Disponível em: <https://blog.infodiagram.com/2024/08/how-present-ai-project-proposal-powerpoint.html>.

Estrutura do pitch de um projeto de IA, com visão da metodologia de ML e uma tabela de custos por elemento do projeto.

Escopo, SOW e dados (partes 06, 07, 12)

[NMS SOW] NMS CONSULTING. “**Consulting SOW Template: Scope, Deliverables, KPIs and Exit Criteria**”. NMS Consulting, 2025. Disponível em: <https://nmsconsulting.com/consulting-sow-template/>.

Modelo de Statement of Work com escopo dentro e fora, premissas, dependências de dados, critérios de aceite e opção de saída após o primeiro sprint.

[nexocode] NEXOCODE. “**AI Project Scoping: How to Define the Scope of an ML Project**”. Nexocode, 2022. Disponível em: <https://nexocode.com/blog/posts/ai-project-scoping-how-to-define-the-scope-of-ml-project/>.

Como definir escopo, entregáveis e KPIs de um projeto de ML alinhados ao objetivo de negócio.

Metodologia e ciclo de vida de ML (partes 04, 05, 08, 14)

[CRISP-ML(Q)] STUDER, S.; BUI, T. B.; DRESCHER, C.; HANUSCHKIN, A.; WINKLER, L.; PETERS, S.; MÜLLER, K.-R. “**Towards CRISP-ML(Q): A Machine Learning Process Model with Quality Assurance Methodology**”. Machine Learning and Knowledge Extraction, v. 3, n. 2, p. 392–413, 2021. DOI: <https://doi.org/10.3390/make3020020>.

Modelo de processo em seis fases com garantia de qualidade e gestão de risco, base para a seção de metodologia e para os riscos da proposta.

[DataSciencePM] DATA SCIENCE PM. “**What is CRISP-DM?**”. Data Science PM, 2024. Disponível em: <https://www.datascience-pm.com/crisp-dm-2/>.

Explica como aplicar o CRISP de forma leve, combinando com gestão ágil, e como a fase de entendimento de negócio define os critérios de sucesso.

[CD4ML] SATO, Danilo; WIDER, Arif; WINDHEUSER, Christoph. “**Continuous Delivery for Machine Learning**”. martinowler.com, 2019. Disponível em: <https://martinowler.com/articles/cd4ml.html>.

Como versionar dados, modelos e código e automatizar o pipeline do treino ao deploy, base para a parte de operação.

[Google Cloud MLOps] GOOGLE CLOUD. “**MLOps: Continuous Delivery and Automation Pipelines in Machine Learning**”. Disponível em: <https://cloud.google.com/architecture/mlops-continuous-delivery-and-automation-pipelines-in-machine-learning>.

Níveis de maturidade de MLOps e como montar CI/CD, treino contínuo e monitoramento em produção.

[Sculley 2015] SCULLEY, D. et al. “**Hidden Technical Debt in Machine Learning Systems**”. NeurIPS, v. 28, p. 2503–2511, 2015.

Artigo seminal sobre o custo de manutenção oculto de sistemas de ML, útil como checklist de riscos e de dívida técnica.

Engenharia de sistemas de ML (partes 05, 06, 14)

[Huyen 2022] HUYEN, Chip. “**Designing Machine Learning Systems**”. O'Reilly Media, 2022.

Projeto de sistemas de ML de ponta a ponta para produção, cobrindo dados, treino, avaliação, deploy e monitoramento.

[Huyen 2025] HUYEN, Chip. “**AI Engineering: Building Applications with Foundation Models**”. O'Reilly Media, 2025.

Construção de aplicações sobre foundation models e LLMs, com avaliação, RAG, fine-tuning e otimização de inferência.

Produto e experiência de IA (partes 05, 15)

[PAIR] GOOGLE PAIR. “**People + AI Guidebook**”. Google, 2019. Disponível em: <https://pair.withgoogle.com/guidebook>.

Boas práticas para desenhar produtos de IA centrados no usuário, com foco em confiança, explicabilidade e tratamento de erros.

Métricas, KPIs e ROI (parte 13)

[Softermii] VANIUKOV, Slava. “**How to Measure ROI from AI Projects: KPIs, Frameworks & Templates**”. Softermii, 2026. Disponível em: <https://softermii.com/blog/artificial-intelligence/how-to-measure-roi-from-ai-projects-kpis-frameworks-and-templates>.

Fórmula de ROI adaptada a IA, categorias de valor, KPIs financeiros e operacionais e templates de cálculo.

[Worklytics] WORKLYTICS. “**Proving ROI on AI Adoption: Metrics and Dashboards**”. Worklytics, 2025. Disponível em: <https://www.worklytics.co/resources/proving-roi-ai-adoption-metrics-dashboards-2025>.

Métricas e dashboards para provar o retorno da adoção de IA ao longo do tempo.

[Agility at Scale] AGILITY AT SCALE. “**AI Business Impact Metrics**”. Disponível em: <https://agility-at-scale.com/ai/strategy/ai-business-impact-metrics/>.

Conjunto de métricas de impacto de negócio para estratégia de IA.

Governança, ética e risco (parte 15)

[NIST AI RMF] NIST. “**Artificial Intelligence Risk Management Framework (AI RMF 1.0)**”. National Institute of Standards and Technology, 2023. Disponível em: <https://www.nist.gov/itl/ai-risk-management-framework>.

Framework de risco em quatro funções, Governar, Mapear, Medir e Gerenciar, ao longo do ciclo de vida da IA.

[ISO 42001] ISO/IEC. “**ISO/IEC 42001:2023: Sistema de Gestão de Inteligência Artificial**”. International Organization for Standardization, 2023. Disponível em: <https://www.iso.org/standard/42001>.

Primeira norma internacional de sistema de gestão de IA, com requisitos para uso responsável e auditável.

[AI Act] PARLAMENTO EUROPEU; CONSELHO DA UNIÃO EUROPEIA. “**Regulamento (UE) 2024/1689 (AI Act)**”. 2024. Disponível em: <https://artificialintelligenceact.eu>.

Marco regulatório abrangente de IA, com abordagem baseada em risco e obrigações proporcionais.

Contexto e estratégia de IA (parte 03)

[Prediction Machines] AGRAWAL, Ajay; GANS, Joshua; GOLDFARB, Avi. “**Prediction Machines: The Simple Economics of Artificial Intelligence**”. Harvard Business Review Press, 2018.

Enquadra a IA como queda no custo da previsão, útil para dimensionar onde ela gera valor no negócio do cliente.

[McKinsey] MCKINSEY & COMPANY (QuantumBlack). “**The State of AI**”. 2025. Disponível em: <https://www.mckinsey.com/capabilities/quantumblack/our-insights/the-state-of-ai>.

Pesquisa anual de adoção de IA nas empresas, com dados sobre onde o valor aparece.

[AI Index] STANFORD HAI. “**The AI Index Report 2025**”. Stanford Institute for Human-Centered AI, 2025. Disponível em: <https://hai.stanford.edu/ai-index/2025-ai-index-report>.

Relatório anual com dados de pesquisa, economia, adoção e política de IA, boa fonte de números para o contexto.

[Enterprise AI Playbook] PEREIRA, Elisa; GRAYLIN, Alvin Wang; BRYNJOLFSSON, Erik. “**The Enterprise AI Playbook: Lessons from 51 Successful Deployments**”. Stanford Digital Economy Lab, 2026. Disponível em: <https://digitaleconomy.stanford.edu>.

Lições de 51 implantações reais, com ênfase em processo, patrocínio e governança sobre a tecnologia.